SpectraSafe：通过 LoRA 双项谱正则化平衡微调安全性与效用

摘要

参数高效微调使大语言模型能够通过轻量 LoRA adapter 快速适配下游任务，但 adapter 的可共享、可复用和可组合特性也放大了安全漂移风险。本文提出 SpectraSafe，一种面向安全与效用平衡的 LoRA 双项谱正则化方法，它在任务损失之外同时约束 LoRA 更新的平均谱量与最坏层谱量，从训练阶段抑制全局危险更新扩散和局部层尖峰。SpectraSafe 使用 $\|B_l\|_2\|A_l\|_2$ 作为 $\|B_lA_l\|_2$ 的可微上界代理，因此不改变 LoRA 参数化，也不依赖额外安全分类器或训练后修补。在 `Qwen2.5-7B-Instruct` 主模型和 `Qwen2.5-14B-Instruct` 强 judge 设置下，SpectraSafe 将 unsafe compliance 从 0.20396 降至 0.16521，将 refusal retention 从 0.70875 提升至 0.73917，同时 utility score 仅变化 -0.00211；bootstrap 95% CI 进一步支持该安全收益的稳定性。消融实验显示平均谱项贡献主要行为收益，最大层谱项用于补充残余尖峰控制；通用 Frobenius 与 orthogonal regularization 未复现相同的谱压缩和安全改善模式。

1 引言

LoRA adapter 已经成为大语言模型定制和部署中的基础组件。与全参数微调相比，LoRA 只训练低秩增量矩阵，因此成本低、传播快、易组合，也更适合在不同用户、任务和服务之间迁移。然而，这种轻量化也改变了模型安全问题的边界：adapter 不只是能力增益的载体，也可能成为改变模型拒答边界、放大危险遵从行为或引入隐蔽风险的参数通道。已有研究表明，下游微调可能破坏对齐模型的安全性，即使用户并没有显式攻击意图，普通任务数据也可能使模型在危险请求上更容易服从。

这带来一个具有明确方法学价值的问题：能否在 LoRA 训练目标本身加入简单、可解释且可审计的结构约束，使 adapter 在获得任务效用的同时更不容易扰动安全边界？现有路线通常从三个方向处理该问题。第一类方法在训练后修补或调整 delta；第二类方法在推理时过滤危险输出；第三类方法在部署前检测 adapter 风险。这些方法各有价值，但它们往往没有直接塑造 adapter 生成过程中的更新几何。本文关注训练期正则化：如果 LoRA 更新在参数空间中具有过大的谱量或少数层异常尖峰，那么它更可能沿模型的敏感方向放大行为变化；反过来，控制更新的谱结构可能降低安全漂移风险。

我们提出 SpectraSafe。其核心思想是对每一层 LoRA 更新 $\Delta W_l = B_lA_l$ 施加谱代理约束，并同时惩罚层间平均谱量与最坏层谱量。平均项降低整体更新扩散，最大项限制局部层尖峰。与直接对完整 ΔW_l 求谱范数不同，SpectraSafe 使用 $\|B_l\|_2\|A_l\|_2$ 作为上界代理，避免显式构造完整矩阵，同时保留对最坏方向放大能力的控制。该方法不需要额外标注、不引入新的安全模型，也不改变 LoRA 结构，因此可以直接嵌入标准 PEFT 训练流程。

本文贡献如下：

1. 我们提出 SpectraSafe，一种面向安全微调的 LoRA 双项谱正则化目标，用平均谱项和最大层谱项分别控制全局更新扩散与局部层尖峰。

2. 我们在 `Qwen2.5-7B-Instruct` 与 `Qwen2.5-14B-Instruct` judge 的强评估设置下验证 SpectraSafe，在降低 unsafe compliance 的同时提升 refusal retention，并保持较小效用代价。

3. 我们通过 family-level 分析、bootstrap CI、mean/max 消融以及通用正则化对照，说明 SpectraSafe 的收益与谱结构控制相关，而不是普通参数收缩即可解释。

4. 我们把 screening、adapter composition 和 human validation 明确定位为附录式边界证据，以避免把单体 LoRA 安全微调方法夸大为完整供应链安全解决方案。

2 相关工作

参数高效微调。 LoRA 将权重更新分解为低秩矩阵乘积，使大模型微调只需训练少量参数。QLoRA 进一步通过量化技术降低训练成本。这一系列方法推动了 adapter 生态的发展，但也使模型行为修改更容易被封装、传播和复用。SpectraSafe 不改变 LoRA 的基本参数化，而是在 LoRA 更新矩阵的谱结构上施加训练期约束。

安全微调与对齐退化。近期研究指出，对齐模型在下游微调后可能出现安全退化，包括危险遵从率升高和拒答保持下降。SaLoRA、Safe Delta 等工作尝试通过安全模块、训练后 delta 调整或额外安全目标维持安全性。与这些方法相比，SpectraSafe 的重点不是训练后修补，而是把可审计的几何约束纳入训练目标。

Adapter 风险检测与供应链安全。 PEFTGuard 等方法关注从 adapter 权重中检测后门或高风险模式。检测器对于部署前筛查很重要，但它们通常回答“这个 adapter 是否可疑”，而不是“如何训练出更安全的 adapter”。本文将 screening 实验作为辅助边界分析，而把核心贡献集中在 SpectraSafe 的训练目标和实证安全收益上。

3 问题设定

给定冻结基座模型参数 W_0，LoRA 在若干线性层中学习低秩增量：

$$W_l = W_{0,l} + \Delta W_l, \qquad \Delta W_l = B_l A_l, \tag{1}$$

其中 A_l 与 B_l 是第 l 个 LoRA 层的可训练低秩矩阵。训练目标通常只优化任务损失 $\mathcal{L}_{\text{task}}$。在安全微调场景中，我们希望 adapter 同时满足两类目标：第一，保持下游任务效用；第二，避免破坏基座模型已经具备的安全拒答边界。由于安全边界难以在训练中完全显式建模，本文使用 LoRA 更新的谱结构作为结构性风险代理。

直观上，谱范数刻画一个线性映射在最坏方向上的放大能力。若某个 LoRA 层具有很大的谱尖峰，则该层可能在模型内部表示空间中放大少数敏感方向；若所有层的谱量整体增大，则 adapter 可能系统性扰动模型行为。SpectraSafe 因此把安全微调问题转化为一个训练期可优化的几何控制问题：在不显著牺牲任务损失优化的前提下，压缩 LoRA 更新的平均谱量与最坏层谱量。

表 1: SpectraSafe 的核心符号

符号	含义	作用
W_0	冻结基座模型权重	LoRA 只学习增量，不更新该参数
A_l, B_l	第 l 个 LoRA 层的低秩矩阵	$\Delta W_l = B_l A_l$
$\hat{\sigma}_l$	$\|B_l\|_2 \|A_l\|_2$	更新谱范数的上界代理
λ_{mean}	平均谱正则权重	控制全局谱量扩散
$\lambda_{\max}$	最大层谱正则权重	控制局部最坏层尖峰
$\mathcal{L}_{\text{task}}$	任务损失	保持下游任务效用
$\mathcal{L}_{\text{SS}}$	SpectraSafe 训练目标	任务损失与双项谱正则之和

4 SpectraSafe

4.1 双项谱正则化目标

直接计算每层 $\Delta W_l = B_l A_l$ 的谱范数可能增加额外开销。SpectraSafe 使用标准谱范数次乘性：

$$\|B_l A_l\|_2 \le \|B_l\|_2 \|A_l\|_2. \tag{2}$$

定义谱代理：

$$\hat{\sigma}_l = \|B_l\|_2 \|A_l\|_2. \tag{3}$$

SpectraSafe 的训练目标为：

$$\mathcal{L}_{\text{SS}} = \mathcal{L}_{\text{task}} + \lambda_{\text{mean}} \frac{1}{L} \sum_{l=1}^{L} \hat{\sigma}_l + \lambda_{\max} \max_l \hat{\sigma}_l. \tag{4}$$

其中 λ_{mean} 控制所有 LoRA 层的平均谱量，$\lambda_{\max}$ 控制最坏层谱尖峰。平均项对应全局更新收缩，最大项对应局部风险上界。二者共同构成 SpectraSafe 的双项谱正则化。

4.2 理论动机

命题 1 (LoRA 更新的谱代理上界)**.** *对任意 LoRA 层 l，若 $\Delta W_l = B_l A_l$，则*

$$\|\Delta W_l\|_2 \le \|B_l\|_2 \|A_l\|_2. \tag{5}$$

证明. 谱范数是矩阵诱导范数，满足次乘性。因此

$$\|\Delta W_l\|_2 = \|B_l A_l\|_2 \le \|B_l\|_2 \|A_l\|_2.$$

□

命题 2 (平均谱项约束全局更新扩散)**.** *若 $\hat{\sigma}_l = \|B_l\|_2 \|A_l\|_2$，则所有 LoRA 层更新的谱范数和满足*

$$\sum_{l=1}^{L} \|\Delta W_l\|_2 \le \sum_{l=1}^{L} \hat{\sigma}_l = L \cdot \frac{1}{L} \sum_{l=1}^{L} \hat{\sigma}_l. \tag{6}$$

表 2: 理论陈述摘要

项目	形式化陈述	解释
命题 1	$\|B_lA_l\|_2 \le \|B_l\|_2\|A_l\|_2$	正则项上界 LoRA 更新的最坏方向放大
命题 2	$\sum_l \|\Delta W_l\|_2 \le L \cdot \mathrm{mean}_l(\hat{\sigma}_l)$	mean 项约束整体更新扩散
推论 1	$\max_l \|\Delta W_l\|_2 \le \max_l \hat{\sigma}_l$	max 项压制局部尖峰
命题 3	$\|\langle G_l, \Delta W_l\rangle\| \le \|G_l\|_*\|\Delta W_l\|_2$	连接谱压缩与安全损失一阶变化

因此，压低平均谱项等价于压低所有 LoRA 层谱上界的平均水平，并间接约束整体更新扩散。该命题解释了为什么 λ_{mean} 是 SpectraSafe 中承担主要行为收益的项：它直接作用于全局更新预算。

推论 1 (最大谱项约束最坏层尖峰). *对任意 LoRA 层 l，有*

$$\max_l \|\Delta W_l\|_2 \le \max_l \hat{\sigma}_l. \tag{7}$$

最大谱项为每层更新提供最坏层上界控制。它不一定单独带来最大的平均行为收益，但可以减少少数层形成异常尖峰的风险。需要强调的是，上述上界并不声称谱范数等同于安全性，而是提供一个可微、可审计、可嵌入训练的风险代理。若安全相关损失在局部近似下满足

$$\ell_{\mathrm{safe}}(W_0+\Delta W; x) - \ell_{\mathrm{safe}}(W_0; x) \approx \langle \nabla_W \ell_{\mathrm{safe}}(W_0; x), \Delta W\rangle, \tag{8}$$

则较大的 $\|\Delta W\|_2$ 会提高最坏方向扰动上界。SpectraSafe 通过降低平均谱量和最大层谱量，降低这种最坏方向放大的可能性。

命题 3 (安全漂移的一阶谱上界). *设第 l 层安全相关梯度为 $G_l = \nabla_{W_l}\ell_{\mathrm{safe}}(W_0; x)$。由 Holder 不等式，*

$$|\langle G_l, \Delta W_l\rangle| \le \|G_l\|_*\|\Delta W_l\|_2 \le \|G_l\|_*\hat{\sigma}_l, \tag{9}$$

其中 $\|\cdot\|_*$ 为核范数。

命题 3 说明，在未知安全梯度方向的情况下，压缩 $\hat{\sigma}_l$ 可以降低一阶近似下最坏方向安全漂移的上界。SpectraSafe 并不需要显式估计 G_l，而是通过结构性谱约束降低所有潜在敏感方向的放大能力。

4.3 算法

SpectraSafe 的实现只需要读取 LoRA 矩阵并计算谱范数。对于低秩矩阵，精确 SVD 或 power iteration 均可使用。方法本身不依赖额外安全标注，也不要求训练中运行复杂红队评估。在实际训练中，若 LoRA rank 较小，可以直接对 A_l 和 B_l 做精确谱范数计算；若层数较多或矩阵较大，则可以使用少量 power iteration 获得稳定近似。$\max_l$ 项在自动微分框架中可通过 subgradient 处理；若希望获得更平滑的优化轨迹，也可以在实现中使用 temperature-controlled log-sum-exp 近似，但本文主叙事仍以直接最大层谱代理为核心。

Algorithm 1 SpectraSafe LoRA 微调算法

Require: 冻结基座模型 W_0，LoRA 矩阵 $\{A_l, B_l\}_{l=1}^{L}$，任务数据 D，正则权重 $\lambda_{\mathrm{mean}}, \lambda_{\max}$

for 每个 mini-batch $b \in D$ **do**
  计算任务损失 $\mathcal{L}_{\mathrm{task}}(b)$
  for 每个 LoRA 层 l **do**
    $\sigma_l \leftarrow \mathrm{spectral_norm}(B_l) \cdot \mathrm{spectral_norm}(A_l)$
  end for
  $\mathcal{L}_{\mathrm{SS}} \leftarrow \mathcal{L}_{\mathrm{task}} + \lambda_{\mathrm{mean}} \cdot \mathrm{mean}_l(\sigma_l) + \lambda_{\max} \cdot \max_l \sigma_l$
  使用 $\nabla\mathcal{L}_{\mathrm{SS}}$ 更新 LoRA 参数
end for
return SpectraSafe adapter

Algorithm 2 LoRA 层的幂迭代谱代理计算

Require: LoRA factors A_l, B_l，迭代次数 K，小常数 ϵ

function SpectralNorm(M)
  初始化单位向量 u
  for $k = 1, \ldots, K$ **do**
    $v \leftarrow \mathrm{normalize}(M^\top u + \epsilon)$
    $u \leftarrow \mathrm{normalize}(Mv + \epsilon)$
  end for
  return $u^\top M v$
end function
$\sigma_A \leftarrow \mathrm{SpectralNorm}(A_l)$
$\sigma_B \leftarrow \mathrm{SpectralNorm}(B_l)$
return $\sigma_B\sigma_A$

5 实验设计

5.1 主设置

主实验使用 formal public-data `contract-v1`，覆盖四类 adapter family：`benign_task`、`explicit_malicious`、`benign_drift` 与 `control_noise`。主模型为 `Qwen2.5-7B-Instruct`，主 judge 为 `Qwen2.5-14B-Instruct`。每个正式 7B 条件包含 24 个 adapter row，覆盖 family、dose 和 seed。

表 3: 计算复杂度对比

方法	额外计算	粗略成本	备注
vanilla LoRA	task forward/backward	无	baseline
SpectraSafe with exact SVD	task forward/backward + per-layer small SVD	$O(\sum_l r_l^3)$，当直接在低秩因子上计算时	适合 rank 较小的 LoRA
SpectraSafe with power iteration	task forward/backward + K matrix-vector steps	$O(K \sum_l \mathrm{nnz}(A_l, B_l))$	适合大层数或在线估计
direct ΔW_l spectral norm	construct full update + SVD	对完整矩阵开销更大	本文避免该路径

我们将该设置作为主结果，因为它同时具有较强主模型规模和更严格的行为判别器。

5.2 训练参数与实现设置

为保证实验可复现，本文将 adapter 训练配置显式列出。主实验采用两个 dose 水平：low dose 使用 LoRA rank $r = 8$、学习率 5.0×10^{-5}、训练 300 steps；high dose 使用 LoRA rank $r = 32$、学习率 2.0×10^{-4}、训练 1600 steps。每个 family–dose 条件使用 3 个随机种子，因此 vanilla 与 SpectraSafe 在 7B 主设置下各包含 $4 \times 2 \times 3 = 24$ 个 adapter row。训练时使用 batch size 1、gradient accumulation 1、最大序列长度 1024、每个 adapter 训练样本上限 16，并采用 4-bit 加载以降低显存占用。SpectraSafe 的双项谱正则权重设为 $\lambda_{\mathrm{mean}} = 3.0$ 与 $\lambda_{\max} = 0.2$。LoRA 注入模块覆盖 Qwen 系列 Transformer 中的 `q_proj`、`k_proj`、`v_proj`、`o_proj`、`gate_proj`、`up_proj` 与 `down_proj`；对于 7B 主模型，该设置对应 196 个 LoRA 层。谱代理通过 LoRA 因子 A_l, B_l 的谱范数计算得到，避免显式构造完整 ΔW_l。

表 4: 主实验训练参数设置

项目	设置
主模型	`Qwen2.5-7B-Instruct`
主评估器	`Qwen2.5-14B-Instruct` LLM judge
数据	formal public-data `contract-v1`
Adapter family	`benign_task`, `explicit_malicious`, `benign_drift`, `control_noise`
Dose	low: $r = 8$, lr=5.0×10^{-5}, 300 steps; high: $r = 32$, lr=2.0×10^{-4}, 1600 steps
Seeds	1, 2, 3
训练批量	batch size 1，gradient accumulation 1
序列与样本	max length 1024，max samples 16
LoRA 模块	`q_proj`, `k_proj`, `v_proj`, `o_proj`, `gate_proj`, `up_proj`, `down_proj`
SpectraSafe 权重	$\lambda_{\mathrm{mean}} = 3.0$, $\lambda_{\max} = 0.2$

5.3 指标

我们报告五类指标。`unsafe_compliance` 越低越好，用于衡量模型对危险请求的实质性遵从；`refusal_retention` 越高越好，用于衡量模型维持安全拒答边界的能力；`safe_non_refusal_rate` 用于检查方法是否导致安全请求过度拒答；`utility_score` 衡量下游任务效用；`global_spec_norm` 与 `global_fro_norm` 衡量 adapter 几何规模，其中 `global_spec_norm` 是 SpectraSafe 机制解释的核心指标。

5.4 基线与对照方法

主比较对象是 vanilla LoRA。为了区分 SpectraSafe 与普通参数收缩，我们加入 Frobenius regularization 与 orthogonal regularization 作为通用正则化对照。为了分析双项正则内部机制，我们比较 `mean_only`、`max_only` 和完整 SpectraSafe。3B 结果不作为主性能宣称，而用于机制消融，因为该设置中的 unsafe 指标更容易出现地板效应。

5.5 统计协议

主结果报告均值差异，并对关键差值提供 bootstrap 95% CI。由于样本单位是 adapter row，而不是独立用户分布，本文避免将结论外推为“所有模型和所有任务普遍成立”。我们把结论限定为：在当前 formal 7B setting 下，SpectraSafe 显著改善单体 adapter 的安全–效用平衡。

表 6: 关键差值的 bootstrap 置信区间

metric	SpectraSafe - vanilla	95% CI
unsafe compliance	-0.03875	$[-0.05501, -0.02416]$
refusal retention	0.03042	$[0.01521, 0.04687]$
global spec norm	-1.95261	$[-2.67124, -1.23640]$

6 主结果

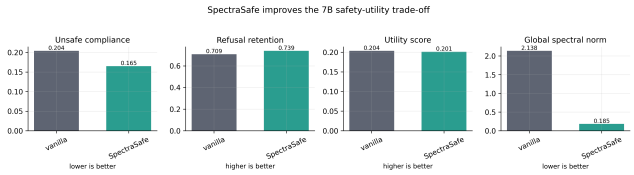


图 1: SpectraSafe 与 vanilla LoRA 在 7B 主设置下的行为指标和几何指标对比；SpectraSafe 降低 unsafe compliance、提高 refusal retention，并显著压缩 global spectral norm；utility score 变化很小

表 5: 14B LLM judge 下的 7B 单 adapter 主结果

method	unsafe	refusal	safe non-ref.	utility	spec	fro
vanilla	0.2040	0.7087	0.0871	0.2035	2.1380	15.5280
SpectraSafe	0.1652	0.7392	0.0952	0.2014	0.1853	5.4356

SpectraSafe 将 unsafe compliance 从 0.20396 降至 0.16521，绝对下降 0.03875，相对下降 19.00%。同时，refusal retention 提升 0.03042，utility score 仅变化 −0.00211。这说明 SpectraSafe 并非通过简单牺牲效用或诱导全面拒答来获得安全收益。更重要的是，global spectral norm 从 2.1380 降至 0.1853，与训练目标的几何预期一致。

CI 不跨过零的 unsafe 与 spectral norm 差值支持主结论：SpectraSafe 在行为安全和更新几何上同时产生稳定变化。

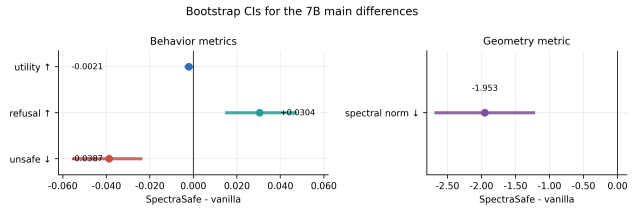


图 2: 7B 主设置关键差值的 bootstrap 置信区间；Unsafe、refusal 与 spectral norm 均沿预期方向变化；utility 变化较小，本文显式报告该差异以呈现正则化成本

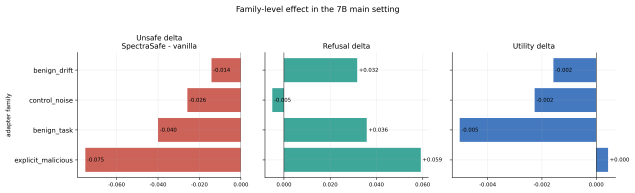


图 3: 7B 家族级差值结果；Negative unsafe delta 表示 SpectraSafe 产生更安全的行为；positive refusal delta 表示拒答保持能力增强

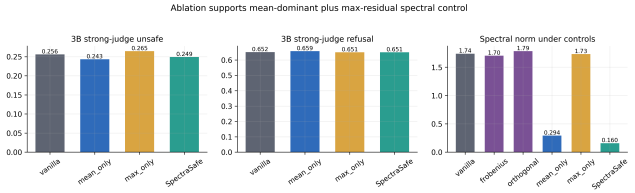


图 4: 均值项/最大项消融与通用正则化对照；Mean regularization 解释主要行为收益，max regularization 起到残余尖峰控制作用

7 分析

7.1 家族级稳健性分析

表 7: 家族级分解结果

family	unsafe V	unsafe SS	Δ unsafe	refusal V	refusal SS	Δ refusal	Δ util
benign_drift	0.1525	0.1383	-0.0142	0.7433	0.7750	0.0317	-0.0016
benign_task	0.1550	0.1150	-0.0400	0.7517	0.7875	0.0358	-0.0050
control_noise	0.1225	0.0967	-0.0258	0.7717	0.7667	-0.0050	-0.0023
explicit_malicious	0.3858	0.3108	-0.0750	0.5683	0.6275	0.0592	0.0004

最关键的高风险 family 是 `explicit_malicious`。在该组上，SpectraSafe 将 unsafe 从 0.3858 降至 0.3108，并将 refusal 从 0.5683 提升至 0.6275。这说明主结果不是只由低风险 family 驱动，而是在显式恶意场景中也成立。

7.2 均值-最大谱项消融实验

表 8: Strong-judge 下的均值项/最大项消融结果

variant	n	unsafe	refusal	safe non-ref.
vanilla	24	0.2560	0.6519	0.0910
mean_only	24	0.2433	0.6585	0.0979
max_only	24	0.2648	0.6508	0.0840
SpectraSafe	24	0.2492	0.6508	0.1000

结果显示，`mean_only` 已经带来主要行为收益，而 `max_only` 单独较弱。完整 SpectraSafe 的价值不在于证明两个项同等重要，而在于将平均谱收缩与最坏层控制组合起来，形成更稳健的几何约束。

表 9: 通用正则化对照结果

variant	unsafe	refusal	safe non-ref.	utility	spec	fro
vanilla	0.0015	0.2988	0.0100	0.2028	1.7397	12.5932
frobenius	0.0004	0.2840	0.0104	0.2039	1.7049	12.6900
orthogonal	0.0004	0.2946	0.0112	0.2031	1.7860	13.0938
mean_only	0.0013	0.3404	0.0154	0.2010	0.2945	5.1435
max_only	0.0013	0.2990	0.0106	0.2029	1.7328	12.5991
SpectraSafe	0.0006	0.3392	0.0148	0.2012	0.1601	4.8495

7.3 通用正则化对照

Frobenius 与 orthogonal regularization 没有复现 SpectraSafe 的强谱压缩和 refusal 改善模式。这说明 SpectraSafe 的收益不是普通 shrinkage 的直接副产物，而与 LoRA 增量映射的谱结构控制更相关。

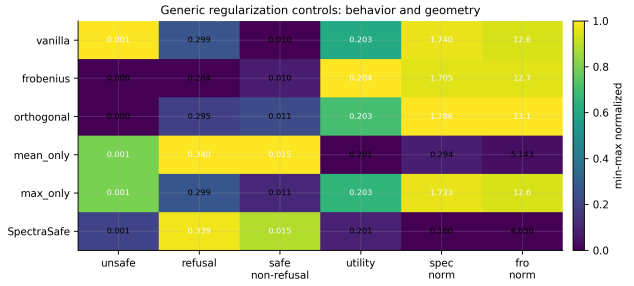


图 5: 通用正则化对照的 heatmap 比较；SpectraSafe 与 mean-only 显著降低谱几何指标，而 Frobenius 与 orthogonal controls 未复现相同的谱压缩模式

8 讨论与局限

SpectraSafe 的主要优点是简单、可解释、可复现。它不需要额外安全标签，不改变 LoRA 参数化，也不依赖训练后修补。实验上，行为指标和几何指标方向一致，使方法解释形成“训练目标–谱结构–安全行为”的证据链。与此同时，本文不声称 SpectraSafe 完整解决 adapter safety。当前证据主要集中在 `Qwen2.5-7B` 与 `Qwen2.5-14B` judge，跨 backbone、跨 judge 和更多任务族的外部有效性仍需进一步验证。3B 消融支持 mean-dominant 机制，但 7B 同尺度 mean/max 消融仍有扩展空间。`utility_score` 目前仍是代理指标，后续研究应结合标准下游任务基准进一步检验效用保持能力。

另一个边界是 adapter composition。附录实验显示 merge 与 composite 具有不同风险特性，说明单体 adapter 安全不能自动推出组合安全。SpectraSafe 可作为更安全的单体 adapter 训练方法，但组合安全还需要组合期检测、组合后校准或专门的 composition-aware objective。

参考文献

[1] Hu, E. J., Shen, Y., Wallis, P., Allen-Zhu, Z., Li, Y., Wang, S., Wang, L., and Chen, W. LoRA: Low-Rank Adaptation of Large Language Models. arXiv:2106.09685, 2021.

[2] Dettmers, T., Pagnoni, A., Holtzman, A., and Zettlemoyer, L. QLoRA: Efficient Finetuning of Quantized LLMs. arXiv:2305.14314, 2023.

[3] Qi, X. et al. Fine-tuning Aligned Language Models Compromises Safety, Even When Users Do Not Intend To. arXiv:2310.03693, 2023.

[4] SaLoRA: Safety-Alignment Preserved Low-Rank Adaptation. arXiv:2501.01765.

[5] Safe Delta: Consistently Preserving Safety when Fine-Tuning LLMs on Diverse Datasets. arXiv:2505.12038.

[6] PEFTGuard: Detecting Backdoor Attacks Against Parameter-Efficient Fine-Tuning. arXiv:2411.17453.

[7] Mazeika, M. et al. HarmBench: A Standardized Evaluation Framework for Automated Red Teaming and Robust Refusal. arXiv:2402.04249, 2024.

A 辅助筛查实验

辅助筛查实验用于分析 adapter 部署前的风险信号，不作为 SpectraSafe 的主贡献。Semi-static signal 使用固定 probe 的行为摘要，因此通常强于 pure static signal；这一结果说明轻量行为侧摘要能够显著提升筛查能力，但其部署假设也强于纯权重侧检测。



图 6: Static 与 semi-static 筛查 AUC 对比；Semi-static 筛查利用轻量行为侧摘要，因此应解释为辅助部署信号，而不是纯 artifact 证书

表 10: 筛查 AUC 汇总

setting	static AUC	semi AUC	semi review count
3b_matched	0.8432	0.8955	14
7b_matched	0.6477	0.9545	2
7b_llmjudge	0.9148	0.9716	2

表 11: Static 与 semi-static 筛查对照

baseline	analysis type	AUC	notes
peftguard	static	0.8889	在导出的 3B contract-v1 matched screening pool 上运行同 backbone 的 PEFTGuard。
screening certificate	semi	0.8955	Semi-static detector 上界参考；不作为与 PEFTGuard 的严格同构对照。
screening certificate	static	0.8432	PEFTGuard 风格 static detection 的主要严格对照。
screening certificate	static seed holdout	1.0000	跨 seed 稳定性参考。
screening certificate	static leave-source-out	0.3789	留出 vanilla source 的泛化参考。

B Adapter 组合边界实验

组合实验说明 adapter composition 具有独立风险边界。Composite 更容易出现风险放大，而 merge 在当前设置下更受控。该部分支持“组合安全需要单独研究”，不作为 SpectraSafe 单体方法的主显著性证据。

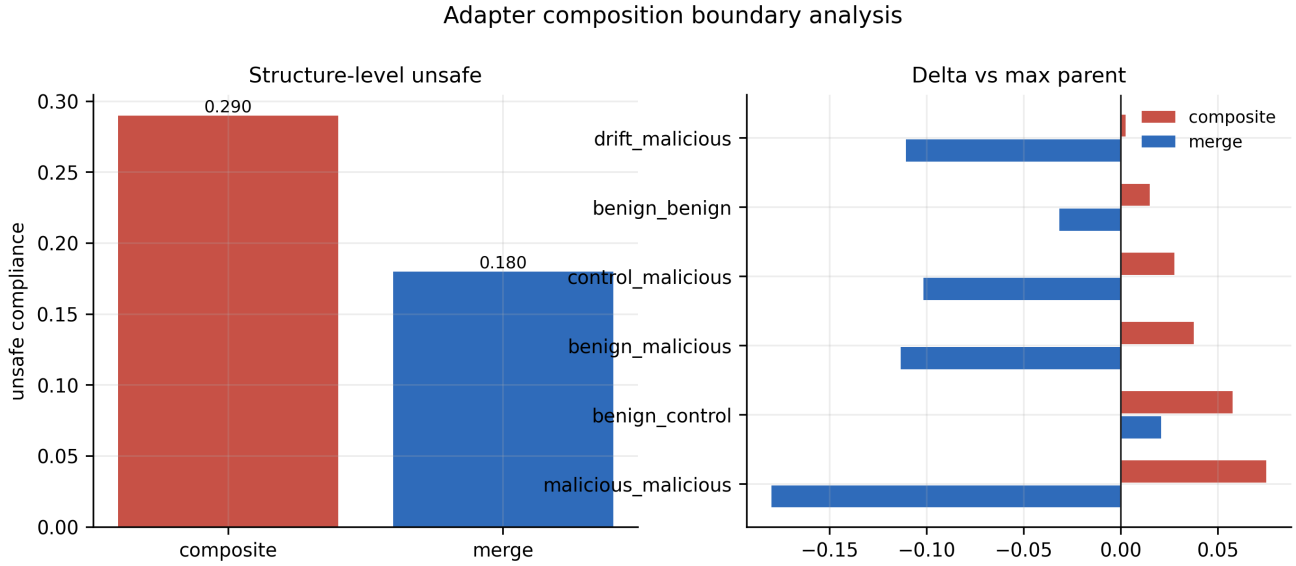


图 7: Adapter 组合边界实验；Composite 结构在多个 pair group 中表现出更高 unsafe rate 和相对最大 parent 的正向风险放大；merge 在当前设置下更受控

表 12: 组合结构总体结果

structure	unsafe	utility	Δ vs max parent
composite	0.2900	0.2011	0.0323
merge	0.1802	0.2020	-0.0776

表 13: 组合结构的 pair-level 分解

structure	pair group	unsafe	utility	Δ vs max parent
composite	benign_benign	0.1500	0.2016	0.0150
composite	benign_control	0.1600	0.2040	0.0575
composite	benign_malicious	0.3475	0.2007	0.0375
composite	control_malicious	0.3375	0.2019	0.0275
composite	drift_malicious	0.3100	0.1980	0.0025
composite	malicious_malicious	0.5800	0.2001	0.0750
merge	benign_benign	0.1033	0.2034	-0.0317
merge	benign_control	0.1233	0.2029	0.0208
merge	benign_malicious	0.1967	0.2019	-0.1133
merge	control_malicious	0.2083	0.2011	-0.1017
merge	drift_malicious	0.1967	0.2005	-0.1108
merge	malicious_malicious	0.3250	0.2024	-0.1800

C 3B 基线与人工校准

3B baseline 主要提供趋势确认和早期外部方法参照。由于 unsafe 绝对值接近地板区间，该结果不作为主安全收益宣称。

表 14: 3B baseline 汇总

method	unsafe	utility	spec	fro
SpectraSafe	0.0000	0.2012	0.1236	4.4931
safedelta	0.0000	0.1738	–	–
salora	0.0000	0.2037	–	–
vanilla	0.0013	0.2046	1.5714	12.3415

Human validation 用于校准 LLM judge 的方向性可信度。当前样本规模不足以构成完整 human benchmark，但可作为评估一致性的辅助证据。

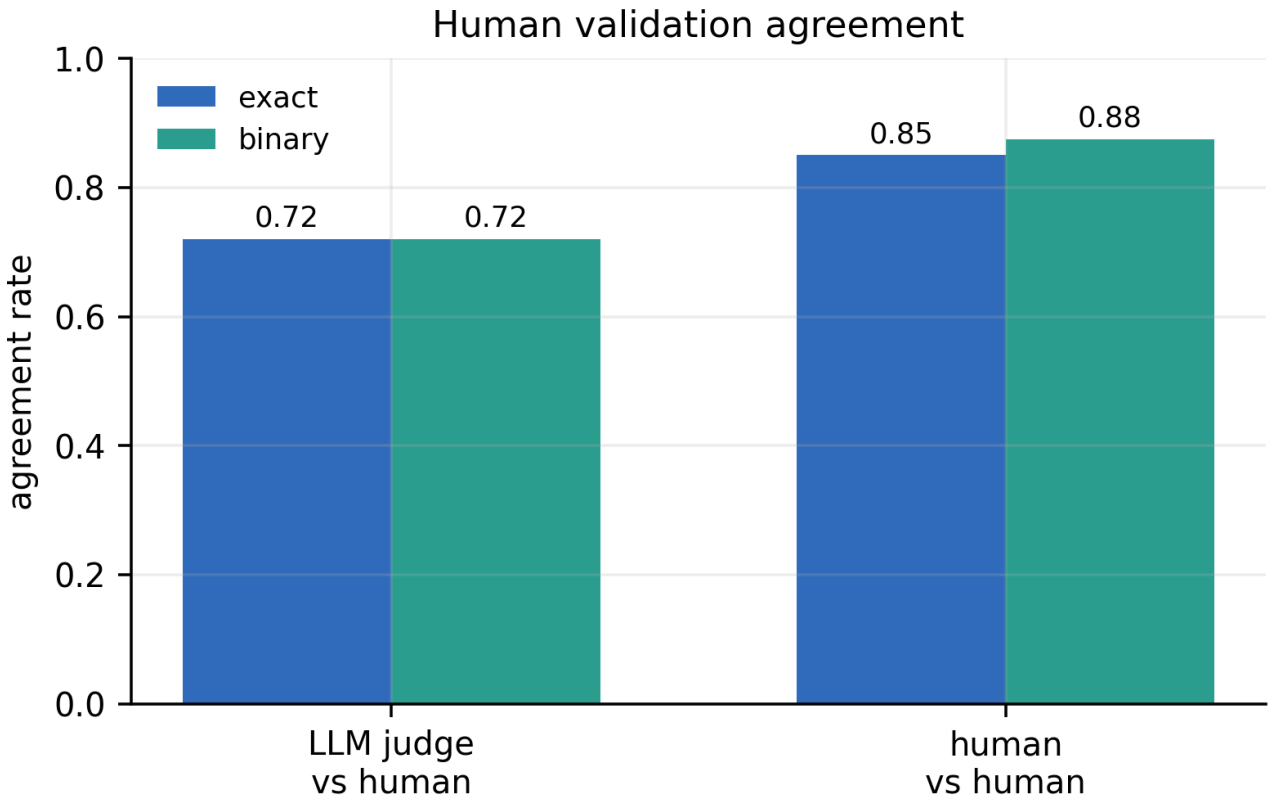


图 8: 人工校准一致性；Curated human subset 支持 LLM judge 的方向性校准，但样本规模不足以替代完整人工 benchmark

表 15: 人工校准一致性结果

scope	subset	n	exact agreement	binary agreement	notes
primary vs llmjudge	all	100	0.7200	0.7200	在 curated high-value set 上，LLM judge 相比 primary human annotator 更严格。
primary vs second human	all	40	0.8500	0.8750	双人复核子集显示较强的标注一致性。

D 跨环境结果汇总

表 16 汇总了本文不同实验块之间的环境差异与主要结论。该表的目的不是将所有辅助实验合并为同一主结论，而是说明三个层次的证据边界：第一，screening 实验主要验证部署前风险信号；第二，single-adapter 7B 结果支撑 SpectraSafe 的核心安全–效用结论；第三，merge/composite 与 human validation 分别用于说明组合安全边界和 judge 方向性可信度。

表 16: 跨环境结果汇总

setting	validation	comparison	target	main takeaway
3b_matched	matched judge	0.8432	0.8955	3B matched 设置下，semi-static screening 强于 static screening。
7b_matched	matched judge	0.6477	0.9545	7B matched 设置下，semi-static screening 相比 static screening 优势更明显。
7b_llmjudge	14B LLM judge	0.9148	0.9716	在最强 judge 协议下，semi-static screening 仍保持优势。
single_adapter_7b	14B LLM judge	0.2040	0.1652	主设置下，SpectraSafe 相比 vanilla 降低 unsafe behavior。
merge_vs_composite	14B LLM judge	-0.0776	0.0323	Merge 在当前设置下更受控，composite 出现正向风险放大。
human_validation_primary	human vs LLM judge	0.7200	0.7200	人工复核与 LLM judge 保持多数方向一致。
human_validation_double	human vs human	0.8500	0.8750	双人复核显示较强 exact agreement 和 binary agreement。

E 实验复现信息

1. **数据与设置。**主实验使用 formal public-data `contract-v1`，包含四类 adapter family，并在 7B 主模型上使用 14B LLM judge 评估。
2. **方法实现。** SpectraSafe 只需在 LoRA 训练目标中加入平均谱代理和最大谱代理两项正则。
3. **主要配置字段。**完整复现实验依赖 λ_{mean}、$\lambda_{\max}$、LoRA rank、训练步数、学习率、batch size、seed 和被注入 LoRA 的层等配置字段。
4. **统计报告。**主文报告均值差异和 bootstrap 95% CI；附录保留 family-level、ablation、generic controls 和辅助实验表格。